

Wykrywanie fake news

Porównanie modeli językowych na zbiorze LIAR

Czerwiec 2026

Klasyfikacja prawdziwości wypowiedzi politycznych na **zbiorze LIAR**.

Dwa warianty zadania:

- **Binarna (2kl):** fake / real
- **Sześcioklasowa (6kl):** pants-fire, false, barely-true, half-true, mostly-true, true


Porównujemy dwa paradygmaty:

- 1 **Fine-tuning encodera** – BERT-base, RoBERTa-base, RoBERTa-large
- 2 **Prompting LLM** – GPT-4o-mini, GPT-4o; darmowe (OpenRouter): gpt-oss-20b, gemma-4-31b-it, dolphin-mistral-24b, llama-3.3-70b-instruct

- 12 791 wypowiedzi z PolitiFact (train 10 240 / val 1 284 / test 1 267)
- Treść + mówca, partia, temat, historia prawdziwości
- Tematy: gospodarka, zdrowie, podatki, edukacja, wybory, imigracja
- Granice między 6 klasami są subiektywne – nawet sami fact-checkerzy z PolitiFact często nie są zgodni przy przypisywaniu wypowiedzi do jednej z sześciu etykiet

Zbiór	Co zawiera
LIAR	treść + metadane mówcy
LIAR-PLUS	LIAR + justification (uzasadnienie fact-checkera)
LIAR2	rozszerzona wersja (22k wypowiedzi, 2024)
LIAR-RAW	surowe dane scrapowane z PolitiFact

Rozkład klas w zbiorze LIAR



Struktura zbioru LIAR

Każda wypowiedź ma 14 kolumn:

Kolumna	Znaczenie
id	unikalny identyfikator wypowiedzi
label	etykieta (<code>pants-fire ... true</code>)
statement	treść wypowiedzi (główny tekst)
subject	temat (np. <code>economy</code> , <code>education</code>)
speaker	mówca
job_title	stanowisko mówcy
state	stan USA
party	partia polityczna
barely_true_counts	liczba poprzednich <code>barely-true</code>
false_counts	liczba poprzednich <code>false</code>
half_true_counts	liczba poprzednich <code>half-true</code>
mostly_true_counts	liczba poprzednich <code>mostly-true</code>
pants_on_fire_counts	liczba poprzednich <code>pants-fire</code>
context	kontekst (np. <code>campaign rally</code> , <code>interview</code>)

Kolumny *_counts to *credit history* – wiarygodność mówcy na podstawie historii.

Każda wypowiedź łączona w jeden tekst:

```
{speaker} ({party}, past lies: N, past truths: M):  
{statement} Subject: {subject} Context: {context}
```

- Mapowanie etykiet 6kl $\rightarrow$ 2kl (*tylko dla modeli dwuklasowych*):
pants-fire/false/barely-true $\rightarrow$ fake,
half-true/mostly-true/true $\rightarrow$ real
- 99,96% wypowiedzi mieści się w 128 tokenach (mediana = 22) – stąd max_length=128 w tokenizacji
- Tokenizacja AutoTokenizer: BPE dla RoBERTy, WordPiece dla BERT-a
- Wagi klas: $w_c = N/(C \cdot n_c)$ przeciwdziałają niezbalansowaniu
- Tensory input_ids, attention_mask, labels opakowane w DataLoader

Performance Ceiling – wyniki z literatury

Wang 2017 – oryginalny paper LIAR (6kl)

Models	Valid.	Test
Majority	0,204	0,208
SVMs	0,258	0,255
Logistic Regression	0,257	0,247
Bi-LSTMs	0,223	0,233
CNNs	0,260	0,270
Hybrid CNNs		
Text + Subject	0,263	0,235
Text + Speaker	0,277	0,248
Text + Job	0,270	0,258
Text + State	0,246	0,256
Text + Party	0,259	0,248
Text + Context	0,251	0,243
Text + History	0,246	0,241
Text + All	0,247	0,274

Źródło: Wang (ACL 2017)

Model	Test Acc	W-F1
Linear SVM (BoW) – 2kl	0,624	0,316
RoBERTa (prior) – 2kl	0,620	–
XGBoost (GloVe, overfit) – 6kl	0,249	–
GPT-3 Curie (fine-tuned) – 6kl	0,295	–

Źródło: emergentmind.com/topics/liar-benchmark

BERT vs RoBERTa

RoBERTa (Robustly Optimized BERT, Liu et al. 2019) – model językowy typu *encoder-only*, oparty na architekturze Transformer. Czyta tekst dwukierunkowo i produkuje gęsty wektor reprezentacji, idealny do klasyfikacji (nie generuje tekstu). *Mechanizm attention*: dla każdego słowa model uczy się jakie *wagi* przypisać innym słowom w zdaniu – w jednym przejściu każdy token może spojrzeć na każdy inny, dzięki czemu model uchwyci długie zależności kontekstowe.

RoBERTa vs BERT:

	BERT (Devlin 2019)	RoBERTa (Liu 2019)
Korpus pretreningu	16 GB (Wiki+Books)	160 GB (+CC-News, OpenWebText)
Maskowanie	statyczne	dynamiczne
Zadanie pretrenu	MLM + NSP	tylko MLM (NSP nie pomaga)
Batch size	256	8K

Testujemy obie wersje – roberta-base i roberta-large:

- roberta-base (125M par., 12 warstw, hidden 768) – mniejszy, szybszy do trenowania
- roberta-large (355M par., 24 warstwy, hidden 1024) – spodziewamy się wyższych wyników kosztem dłuższego treningu

Stosowane metryki:

- **accuracy** – udział poprawnych predykcji
- **precision, recall** per klasa (oraz średnie macro / weighted)
- **F1** per klasa – $F_1 = \frac{2 \cdot \text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}}$
- **weighted-F1** – średnia F1 ważona supportem klas
- **macro-F1** – nasza główna metryka:

$$\text{macro-F1} = \frac{1}{C} \sum_{c=1}^C F_1^{(c)}$$

średnia arytmetyczna F1 z każdej klasy, bez ważenia liczebnością – traktuje każdą klasę jednakowo i karze model za ignorowanie klas rzadkich, kluczowych w fact-checkingu (np. pants-fire)

- **ROC AUC** (one-vs-rest) – jak dobrze model rankuje klasy
- **macierz pomyłek** – które klasy mylą się ze sobą

Techniki podnoszące jakość

- **Wagi klas** (Cross-Entropy z $w_c = N/(C \cdot n_c)$)
- **Label smoothing** ($\varepsilon = 0,1$)
- **Optuna** – 20 triali, TPE sampler, MedianPruner
- **Early stopping** po val macro-F1
- **Linear warmup + decay** schedulera lr
- **Structured Outputs** (GPT) – JSON schema, 0 unparsed
- **Self-consistency** (GPT) – N=3 niezależne predykcje + voting
- **Few-shot kNN retrieval** – TF-IDF cosine similarity

Optuna – automatyczne strojenie hiperparametrów

Co to: framework do automatycznego wyszukiwania hiperparametrów.

- **TPE Sampler** – Bayesowski wybór kolejnych prób, uczy się z wcześniejszych
- **MedianPruner** – ucina słabe triale po E1 (poniżej mediany), oszczędza GPU

Uzasadnienie użycia: 50 kombinacji ręcznie = dni GPU; Optuna 20 prób = 2h.

Efekt: val F1 0,71 → **0,7435** (+3 pkt).

Best params z 2kl stosujemy też do treningu 6kl (i 6kl + LIAR-PLUS), czasem z ręcznym dopasowaniem (epochs, weight_decay) pod większą trudność zadania.

Best params (2kl):

parametr	wartość
learning rate	$5,79 \cdot 10^{-6}$
weight decay	0,124
epochs	5
batch size	8
val F1	0,7435

Wyniki – GPT (OpenAI API) + darmowe LLM

Model	2kl Acc	2kl Macro-F1	6kl Acc	6kl Macro-F1
OpenRouter (darmowe) – w trakcie ewaluacji				
gpt-oss-20b (ZS)	0,467	0,407	—	—
gemma-4-31b-it	—	—	—	—
dolphin-mistral-24b	—	—	—	—
llama-3.3-70b-instruct	—	—	—	—
GPT (OpenAI, płatne)				
GPT-4o-mini zero-shot	0,696	0,695	0,298	0,279
GPT-4o-mini few-shot	0,693	0,686	0,324	0,310
GPT-4o zero-shot (SC=3, SO)	0,729	0,729	—	—
GPT-4o few-shot	0,710	0,709	0,344	0,356

Wyniki – fine-tuning encoderów

Model	2kl Acc	2kl Macro-F1	6kl Acc	6kl Macro-F1
BERT-base-uncased	0,628	0,604	—	—
RoBERTa-base	0,640	0,622	—	—
RoBERTa-large baseline	0,738	0,728	—	—
RoBERTa-large + Optuna	—	—	0,357	0,359
RoBERTa-large + LIAR-PLUS	—	—	0,355	0,341

- **Structured Outputs** – każemy modelowi odpowiadać tylko jednym słowem (fake lub true), zero zbędnego tekstu
- **Few-shot kNN** – wklejamy do promptu kilka przykładów ze zbioru treningowego najbardziej podobnych do pytanego zdania
- **Self-consistency** – pytamy model 3 razy, bierzemy odpowiedź, która padła najczęściej

Najlepsze wyniki z każdej kategorii

Kategoria	Model	2kl Macro-F1	6kl Macro-F1
Encoder (fine-tune)	RoBERTa-large (+ LIAR-PLUS na 6kl)	0,728	0,341
LLM płatny (API)	gpt-4o (SC=3, SO / few-shot)	0,729	0,356

- 2kl: **remis** – RoBERTa-large $\approx$ gpt-4o (0,728 vs 0,729)
- 6kl: **GPT-4o** (0,356) nieznacznie wyprzedza RoBERTa-large + LIAR-PLUS (0,341)

Eksperyment	Czas	Per próbka
GPT-4o-mini (API) – 1267 próbek		
2kl zero-shot	94 s	75 ms
2kl few-shot	163 s	130 ms
6kl zero-shot	714 s (~12 min)	560 ms
6kl few-shot	4001 s (~67 min)	3,2 s
GPT-4o (API, próba 2)		
2kl zero-shot SC=3	160 s	125 ms
6kl few-shot K=1 SC=1	2007 s (~33 min)	1,6 s
RoBERTa-large (A100, trening + ewaluacja)		
2kl trening 5 epok	~10 min	—
Optuna 2kl (20 triali)	~2 h	—
6kl_plus 7 epok	~25 min	—

- **Fine-tuning vs prompting:**

- 2kl: RoBERTa-large $\geq$ GPT-4o (lokalnie, 0\$ inferencji)
- 6kl: GPT-4o $\geq$ RoBERTa (wiedza o świecie)
- RoBERTa-large + LIAR-PLUS – nasze najlepsze 6kl

- **Few-shot nie pomaga** w fact-checkingu – przykłady uczą modelu *formatu odpowiedzi*, ale nie dostarczają wiedzy potrzebnej do oceny prawdziwości nowej, niezwiązanej wypowiedzi (prawdziwość zależy od faktów o świecie, nie od wzorca)
- **Structured Outputs** – musi być (z 11% unparsed do 0%)
- **Macro-F1, nie accuracy** – niezbalansowane klasy
- **Performance ceiling 6kl** ($\sim 0,32$) przekroczyliśmy dzięki LIAR-PLUS