

Wykrywanie fake news

Porównanie modeli językowych na zbiorze LIAR

Czerwiec 2026

Klasyfikacja prawdziwości wypowiedzi politycznych na **zbiorze LIAR**.

Dwa warianty zadania:

- **Binarna:** fake / real
- **Sześcioklasowa:** pants-fire, false, barely-true, half-true, mostly-true, true

Porównujemy dwa paradygmaty:

- 1 **Fine-tuning encodera** – BERT-base, RoBERTa-base, RoBERTa-large
- 2 **Prompting LLM** – GPT-4o-mini, GPT-4o; darmowe (OpenRouter): gpt-oss-20b, gemma-4-31b-it, dolphin-mistral-24b, llama-3.3-70b-instruct


- 12 791 wypowiedzi z PolitiFact (train 10 240 / val 1 284 / test 1 267)
- Treść + mówca, partia, temat, historia prawdziwości
- Tematy: gospodarka, zdrowie, podatki, edukacja, wybory, imigracja
- Granice między 6 klasami są subiektywne – nawet sami fact-checkerzy z PolitiFact często nie są zgodni przy przypisywaniu wypowiedzi do jednej z sześciu etykiet

Zbiór	Co zawiera
LIAR	treść + metadane mówcy
LIAR-PLUS	LIAR + justification (uzasadnienie fact-checkera)
LIAR2	rozszerzona wersja (22k wypowiedzi, 2024)
LIAR-RAW	surowe dane scrapowane z PolitiFact

Przykładowe wypowiedzi z LIAR

- [pants-fire] *Says under his budget-repair bill, collective bargaining is fully intact.*
- [false] *If the Supreme Court throws out the federal health care law, it would be an unprecedented, extraordinary step of overturning a law that was passed by a strong majority of a democratically elected Congress.*
- [barely-true] *With Obamacare, we're fixing to get hit with the biggest entitlement program the American taxpayers have ever seen.*
- [half-true] *Since the passage of the Affordable Care Act, U.S. health care spending grew at 3.9 percent for the last three years, the lowest growth rate in over 50 years.*
- [mostly-true] *There are more members of the U.S. Senate than the number of WI families who would benefit from GOP estate tax break.*
- [true] *Says he cut taxes by more than \$600 million when he was governor.*

Rozkład klas w zbiorze LIAR



Struktura zbioru LIAR

Każda wypowiedź ma 14 kolumn:

Kolumna	Znaczenie
id	unikalny identyfikator wypowiedzi
label	etykieta (<code>pants-fire ... true</code>)
statement	treść wypowiedzi (główny tekst)
subject	temat (np. <code>economy</code> , <code>education</code>)
speaker	mówca
job_title	stanowisko mówcy
state	stan USA
party	partia polityczna
barely_true_counts	liczba poprzednich <code>barely-true</code>
false_counts	liczba poprzednich <code>false</code>
half_true_counts	liczba poprzednich <code>half-true</code>
mostly_true_counts	liczba poprzednich <code>mostly-true</code>
pants_on_fire_counts	liczba poprzednich <code>pants-fire</code>
context	kontekst (np. <code>campaign rally</code> , <code>interview</code>)

Kolumny `*_counts` to *credit history* – wiarygodność mówcy na podstawie historii.

Każda wypowiedź łączona w jeden tekst:

```
{speaker} ({party}, past lies: N, past truths: M):  
{statement} Subject: {subject} Context: {context}
```

- Mapowanie etykiet 6kl $\rightarrow$ 2kl (*tylko dla modeli dwuklasowych*):
pants-fire/false/barely-true $\rightarrow$ fake,
half-true/mostly-true/true $\rightarrow$ real
- 99,96% wypowiedzi mieści się w 128 tokenach (mediana = 22) – stąd max_length=128 w tokenizacji
- Tokenizacja AutoTokenizer: BPE dla RoBERTy, WordPiece dla BERT-a
- Wagi klas: $w_c = N/(C \cdot n_c)$ przeciwdziałają niezbalansowaniu
- Tensory input_ids, attention_mask, labels opakowane w DataLoader

Preprocessing i tokenizacja

Preprocessing:

- lowercase – `str.lower()`
- usunięcie URL-i – `re.sub()`
- usunięcie interpunkcji – `re.sub()` + `string.punctuation`

PRZED: Says the economy is doing better than ever!

PO: says the economy is doing better than ever

Tokenizacja: AutoTokenizer zamienia tekst na 2 wektory – `input_ids` (ID tokenów + `<s>/</s>` + padding) oraz `attention_mask` (1 = token, 0 = padding).

Tekst: Says the economy is doing better than ever.


Tokeny:

`['<s>', 'S', 'ays', 'Ġthe', 'Ġeconomy', 'Ġis', 'Ġdoing', 'Ġbetter', 'Ġthan', 'Ġever', '.', '</s>']`

IDs: `[0, 104, 4113, 5, 866, 16, 608, 357, 87, 655, 4, 2]`

Prefiks `Ġ` = spacja przed tokenem. `<s>/</s>` = znaczniki początku/końca.

Rozkład długości wypowiedzi



Mediana = 22 tokeny, średnia = 24,1. Stąd `max_length=128` w tokenizacji.

Performance Ceiling – wyniki z literatury

Wang 2017 – oryginalny paper LIAR (6kl)

Models	Valid.	Test
Majority	0,204	0,208
SVMs	0,258	0,255
Logistic Regression	0,257	0,247
Bi-LSTMs	0,223	0,233
CNNs	0,260	0,270
Hybrid CNNs		
Text + Subject	0,263	0,235
Text + Speaker	0,277	0,248
Text + Job	0,270	0,258
Text + State	0,246	0,256
Text + Party	0,259	0,248
Text + Context	0,251	0,243
Text + History	0,246	0,241
Text + All	0,247	0,274

Źródło: Wang (ACL 2017)

Model	Test Acc	W-F1
Linear SVM (BoW) – 2kl	0,624	0,316
RoBERTa (prior) – 2kl	0,620	–
XGBoost (GloVe, overfit) – 6kl	0,249	–
GPT-3 Curie (fine-tuned) – 6kl	0,295	–

Źródło: emergentmind.com/topics/liar-benchmark

BERT vs RoBERTa

RoBERTa (Robustly Optimized BERT, Liu et al. 2019) – model językowy typu *encoder-only*, oparty na architekturze Transformer. Czyta tekst dwukierunkowo i produkuje gęsty wektor reprezentacji, idealny do klasyfikacji (nie generuje tekstu). *Mechanizm attention*: dla każdego słowa model uczy się jakie *wagi* przypisać innym słowom w zdaniu – w jednym przejściu każdy token może spojrzeć na każdy inny, dzięki czemu model uchwyci długie zależności kontekstowe.

RoBERTa vs BERT:

	BERT (Devlin 2019)	RoBERTa (Liu 2019)
Korpus pretreningu	16 GB (Wiki+Books)	160 GB (+CC-News, OpenWebText)
Maskowanie	statyczne	dynamiczne
Zadanie pretrenu	MLM + NSP	tylko MLM (NSP nie pomaga)
Batch size	256	8K

Testujemy obie wersje – roberta-base i roberta-large:

- roberta-base (125M par., 12 warstw, hidden 768) – mniejszy, szybszy do trenowania
- roberta-large (355M par., 24 warstwy, hidden 1024) – spodziewamy się wyższych wyników kosztem dłuższego treningu

Stosowane metryki:

- **Accuracy** – udział poprawnych predykcji
- **Precision, Recall** per klasa (oraz średnie macro / weighted)
- **F1** per klasa – $F_1 = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$
- **Weighted-F1** – średnia F1 ważona supportem klas
- **Macro-F1** – nasza główna metryka:

$$\text{Macro-F1} = \frac{1}{C} \sum_{c=1}^C F_1^{(c)}$$

średnia arytmetyczna F1 z każdej klasy, bez ważenia liczebnością – traktuje każdą klasę jednakowo i karze model za ignorowanie klas rzadkich, kluczowych w fact-checkingu (np. pants-fire)

- **ROC AUC** (one-vs-rest) – jak dobrze model rankuje klasy
- **Macierz pomyłek** – które klasy mylą się ze sobą

- **Wagi klas** (Cross-Entropy z $w_c = N/(C \cdot n_c)$)
- **Label smoothing** ($\varepsilon = 0,1$)
- **Optuna** – 20 triali, TPE sampler, MedianPruner
- **Early stopping** po val macro-F1
- **Linear warmup + decay** schedulera lr
- **Structured Outputs** (GPT) – JSON schema, 0 unparsed
- **Self-consistency** (GPT) – N=3 niezależne predykcje + voting
- **Few-shot kNN retrieval** – TF-IDF cosine similarity

Optuna – automatyczne strojenie hiperparametrów

Co to: framework do automatycznego wyszukiwania hiperparametrów.

- **TPE Sampler** – Bayesowski wybór kolejnych prób, uczy się z wcześniejszych
- **MedianPruner** – ucina słabe triale po E1 (poniżej mediany), oszczędza GPU

Uzasadnienie użycia: 50 kombinacji ręcznie = dni GPU; Optuna 20 prób = 2h.

Efekt: val F1 0,71 → **0,7435** (+3 pkt).

Best params z 2kl stosujemy też do treningu 6kl (i 6kl + LIAR-PLUS), czasem z ręcznym dopasowaniem (epochs, weight_decay) pod większą trudność zadania.

Best params:

parametr	wartość
learning rate	$5,79 \cdot 10^{-6}$
weight decay	0,124
epochs	5
batch size	8
val F1	0,7370

Wyniki – fine-tuning encoderów

Model	2kl Acc	2kl Macro-F1	6kl Acc	6kl Macro-F1
BERT-base-uncased	0,628	0,604	—	—
RoBERTa-base	0,640	0,622	—	—
RoBERTa-large + Optuna	0,738	0,728	0,357	0,359
RoBERTa-large + LIAR-PLUS	—	—	0,355	0,341


Najlepszy wynik RoBERTa-large + Optuna (2kl)

Classification report:

	precision	recall	f1-score	support
fake	0,733	0,629	0,677	553
real	0,741	0,822	0,780	714
accuracy			0,738	1267
macro avg	0,737	0,726	0,728	1267
weighted avg	0,737	0,738	0,735	1267

ROC AUC: 0,806 balanced acc: 0,726

Macierz pomyłek:




Najlepszy wynik RoBERTa-large + Optuna (6kl)

Classification report:

	precision	recall	f1-score	support
pants-fire	0,423	0,359	0,388	92
false	0,490	0,406	0,444	249
barely-true	0,253	0,236	0,244	212
half-true	0,348	0,328	0,338	265
mostly-true	0,331	0,382	0,355	241
true	0,346	0,428	0,383	208
accuracy			0,357	1267
macro avg	0,365	0,356	0,359	1267
weighted avg	0,362	0,357	0,357	1267

balanced acc: 0,356

Macierz pomyłek:



Tryby promptingu + darmowe LLM z OpenRouter

Tryby promptingu:

- **Zero-shot** – tylko polecenie i zdanie do oceny, bez przykładów
- **Few-shot** – przed pytanym zdaniem wklejamy K oznaczonych przykładów na klasę (model uczy się wzorca w locie)

Darmowy model (OpenRouter):

Model	Wielkość	Specyfika
gpt-oss-20b	20B	Model z trybem <i>reasoning</i> – najpierw rozumuje

Open-source model od OpenAI udostępniony przez OpenRouter za darmo. Dekoder-only Transformer z 20 mld parametrów, trenowany do generowania odpowiedzi z wewnętrznym łańcuchem rozumowania (chain-of-thought) przed finalnym wynikiem.

Techniki użyte w GPT + porównanie modeli

Przepływ zdania przez pipeline:

- **Zero-shot:** zdanie + metadane → prompt (system + zdanie) → API → etykieta
- **Few-shot:** zdanie + metadane → top-K podobnych przykładów z treningu (per klasa, kNN) → prompt (system + przykłady + zdanie) → API → etykieta

Techniki użyte w GPT:

- **Structured Outputs** – model odpowiada tylko jednym słowem
- **Few-shot kNN** – wklejamy przykłady o najpodobniejszej tematyce zamiast losowych
- **Self-consistency** – pytamy 3 razy, większościowe głosowanie
- **Asynchroniczne zapytania** – równoległe wywołania API; redukuje czas runu z ~ 30 min do ~ 3 min.
Wartość CONCURRENCY dobrana do limitu rate limit danego modelu: 20 dla gpt-4o-mini, 8 dla gpt-4o

gpt-4o-mini vs gpt-4o:

	gpt-4o-mini	gpt-4o
Wielkość	$\sim 8B$	$\sim 200B$
Cena (in/out)	\$0.15 / \$0.60 per 1M ($\sim 17\times$ tańszy)	\$2.50 / \$10 per 1M
Szybkość	$\sim 2\times$ szybszy	wolniejszy
Jakość	słabszy w trudnych zadaniach	flagowy


Wyniki – GPT (OpenAI API) + darmowe LLM

Model	2kl Acc	2kl Macro-F1	6kl Acc	6kl Macro-F1
OpenRouter (darmowe)				
gpt-oss-20b zero-shot	0,467	0,407	—	—
gpt-oss-20b few-shot	0,500	0,467	—	—
GPT (OpenAI, płatne)				
GPT-4o-mini zero-shot	0,696	0,695	0,298	0,279
GPT-4o-mini few-shot	0,693	0,686	0,324	0,310
GPT-4o zero-shot (SC=3, SO)	0,729	0,729	—	—
GPT-4o few-shot	0,710	0,709	0,344	0,356

Najlepszy wynik GPT-4o (2kl zero-shot, SC=3, SO)

Classification report:

	precision	recall	f1-score	support
fake	0,66	0,78	0,71	553
real	0,80	0,69	0,74	714
accuracy			0,73	1267
macro avg	0,73	0,73	0,73	1267
weighted avg	0,74	0,73	0,73	1267




Najlepszy wynik GPT-4o (6kl few-shot, K=1, SO)

Classification report:

	precision	recall	f1-score	support
pants-fire	0,72	0,36	0,48	91
false	0,34	0,48	0,40	244
barely-true	0,26	0,40	0,32	211
half-true	0,28	0,36	0,32	263
mostly-true	0,44	0,15	0,22	239
true	0,51	0,32	0,39	206
accuracy			0,34	1254
macro avg	0,43	0,35	0,36	1254
weighted avg	0,39	0,34	0,34	1254

Macierz pomyłek:



Najlepsze wyniki z każdej kategorii

Kategoria	Model	2kl Macro-F1	6kl Macro-F1
Encoder	RoBERTa-large (+ LIAR-PLUS na 6kl)	0,728	0,341
LLM płatny	gpt-4o (SC=3, SO / few-shot)	0,729	0,356

- 2kl: **remis** – RoBERTa-large $\approx$ gpt-4o (0,728 vs 0,729)
- 6kl: **GPT-4o** (0,356) nieznacznie wyprzedza RoBERTa-large + LIAR-PLUS (0,341)

Eksperyment	Czas	Per próbka
GPT-4o-mini (API) – 1267 próbek		
2kl zero-shot	94 s	75 ms
2kl few-shot	163 s	130 ms
6kl zero-shot	714 s (~12 min)	560 ms
6kl few-shot	4001 s (~67 min)	3,2 s
GPT-4o (API, próba 2)		
2kl zero-shot SC=3	160 s	125 ms
6kl few-shot K=1 SC=1	2007 s (~33 min)	1,6 s
RoBERTa-large (A100, trening + ewaluacja)		
2kl trening 5 epok	~10 min	—
Optuna 2kl (20 triali)	~2 h	—
6kl_plus 7 epok	~25 min	—

- **Fine-tuning vs prompting:**

- 2kl: RoBERTa-large $\geq$ GPT-4o (lokalnie, 0\$ inferencji)
- 6kl: GPT-4o $\geq$ RoBERTa (wiedza o świecie)
- RoBERTa-large + LIAR-PLUS – nasze najlepsze 6kl

- **Few-shot nie pomaga** w fact-checkingu – przykłady uczą modelu *formatu odpowiedzi*, ale nie dostarczają wiedzy potrzebnej do oceny prawdziwości nowej, niezwiązanej wypowiedzi (prawdziwość zależy od faktów o świecie, nie od wzorca)
- **Structured Outputs** – musi być (z 11% unparsed do 0%)
- **Macro-F1, nie accuracy** – niezbalansowane klasy
- **Performance ceiling 6kl** ($\sim 0,32$) przekroczyliśmy dzięki LIAR-PLUS

- **Klasyfikacja kaskadowa** – RoBERTa najpierw rozstrzyga 2 klasy (fake/real), potem w obrębie każdej grupy drugi model przypisuje jedną z trzech oryginalnych etykiet LIAR. Każdy model specjalizuje się w prostszym zadaniu.
- **Porównanie różnych kombinacji preprocessingu** – ablacja poszczególnych kroków (lowercase, URL, interpunkcja, kontekst mówcy, `max_length`) i ich wpływu na wyniki.
- **Porównanie wersji zbioru LIAR** – LIAR vs. LIAR-PLUS vs. LIAR2 vs. LIAR-RAW. Każdy daje inny zakres metadanych i może poprawić wyniki, szczególnie w wariancie 6-klasowym.