

Wykrywanie fake news

Porównanie modeli językowych na zbiorze LIAR

Czerwiec 2026

Klasyfikacja prawdziwości wypowiedzi politycznych na **zbiorze LIAR**.

Dwa warianty zadania:

- **Binarna (2kl):** fake / real
- **Sześcioklasowa (6kl):** pants-fire, false, barely-true, half-true, mostly-true, true

Porównujemy trzy paradygmaty:

- 1 **Fine-tuning encodera** – RoBERTa-large
- 2 **Prompting LLM (płatny)** – GPT-4o-mini, GPT-4o
- 3 **Prompting LLM (open-source)** – Qwen 2.5 3B

- 12 791 krótkich wypowiedzi z PolitiFact (Wang 2017)
- Splits: train 10 240, val 1 284, test 1 267
- Każda wypowiedź ma: treść, mówcę, partię, historię prawdziwości
- Tematy: gospodarka, opieka zdrowotna, podatki, edukacja, wybory, imigracja

Trudność:

- Niezbalansowane klasy (najrzadsza pants-fire = 8%)
- Granice między klasami subiektywne – nawet fact-checkerzy się nie zgadzają
- Wymaga wiedzy o świecie, nie tylko analizy stylu

Każda wypowiedź łączona w jeden tekst:

```
{speaker} ({party}, past lies: N, past truths: M):  
{statement} Subject: {subject} Context: {context}
```

- Mapowanie etykiet 6kl $\rightarrow$ 2kl: pants-fire/false/barely-true $\rightarrow$ fake, half-true/mostly-true/true $\rightarrow$ real
- Tokenizacja AutoTokenizer (RoBERTa BPE), max_length=128
- 99,96% wypowiedzi mieści się w 128 tokenach (mediana = 22)
- Wagi klas: $w_c = N/(C \cdot n_c)$ przeciwdziałają niezbalansowaniu
- Tensory input_ids, attention_mask, labels opakowane w DataLoader

Systematyczny przegląd literatury (emergentmind.com) potwierdza:

- **6kl**: accuracy nie przekracza $\sim 0,32$
- **2kl**: $\sim 0,62$ (SVM/RoBERTa baseline)
- Modele drzewiaste: 99% train, ale 25% test = czysty overfit

Nawet Wang 2017 (oryginalny paper LIAR) osiągnął tylko **0,274 acc** dla 6kl.

RoBERTa – czym jest i dlaczego ją wybraliśmy

RoBERTa (Robustly Optimized BERT, Liu et al. 2019) – model językowy typu *encoder-only*, oparty na architekturze Transformer. Czyta tekst dwukierunkowo i produkuje gęsty wektor reprezentacji, idealny do klasyfikacji (nie generuje tekstu).

RoBERTa vs BERT:

	BERT (Devlin 2019)	RoBERTa (Liu 2019)
Korpus pretreningu	16 GB (Wiki+Books)	160 GB (+CC-News, OpenWebText)
Maskowanie	statyczne	dynamiczne
Zadanie pretrenu	MLM + NSP	tylko MLM (NSP nie pomaga)
Batch size	256	8K

Wybór roberta-large (355M parametrów):

- Bogatsza wiedza ogólna – $10\times$ większy korpus istotny w domenie newsów
- Lepsze reprezentacje pojedynczych zdań (brak NSP) – pasuje do klasyfikacji
- Test 2kl: **0,738** vs BERT-base $\sim 0,65$ (literatura)

Wybór metryki: macro-F1

Klasyfikacja LIAR jest **niezbalansowana** – klasy mają różne liczebności (pants-fire 8% vs half-true 21%).

Co stosujemy:

- **macro-F1** – średnia arytmetyczna F1 dla każdej klasy, *bez ważenia liczebnością*.
- Każda klasa liczy się tak samo, niezależnie od support.

Czemu nie accuracy / weighted-F1:

- Model przewidujący zawsze half-true dostałby accuracy 21% za darmo, choć kompletnie nie umie klasyfikować
- Weighted-F1 jest dominowane przez klasy większościowe – maskuje słabe wyniki na rzadkich klasach (pants-fire)
- Macro-F1 **karze** model za ignorowanie klas mniejszościowych – co jest krytyczne w fact-checkingu (najgorsze kłamstwa pants-fire są też najrzadsze)

Wniosek: macro-F1 mierzy rzeczywistą zdolność modelu do rozpoznawania wszystkich klas, nie tylko tych łatwych.

Techniki podnoszące jakość

- **Wagi klas** (Cross-Entropy z $w_c = N/(C \cdot n_c)$)
- **Label smoothing** ($\varepsilon = 0,1$)
- **Optuna** – 20 trials, TPE sampler, MedianPruner
- **Early stopping** po val macro-F1
- **Mixed precision bfloat16** – $2\times$ szybciej na A100
- **Linear warmup + decay** schedulera lr
- **Structured Outputs** (GPT) – JSON schema, 0 unparsed
- **Self-consistency** (GPT) – $N=3$ niezależne predykcje + voting
- **Few-shot kNN retrieval** – TF-IDF cosine similarity

Selekcja po macro-F1, nie accuracy – niezbalansowane klasy.

Optuna – automatyczne strojenie hiperparametrów

Co to: framework do automatycznego wyszukiwania hiperparametrów.

- **TPE Sampler** – Bayesowski wybór kolejnych prób, uczy się z wcześniejszych
- **MedianPruner** – ucina słabe triale po E1 (poniżej mediany), oszczędza GPU

Po co: 50 kombinacji ręcznie = dni GPU;
Optuna 20 prób = 2h.

Efekt: val F1 0,71 → **0,7435** (+3 pkt).

Best params (2kl):

parametr	wartość
learning rate	$5,79 \cdot 10^{-6}$
weight decay	0,124
epochs	5
batch size	8
val F1	0,7435

Wyniki – klasyfikacja binarna (2kl)

Model	accuracy	macro-F1
GPT-4o-mini zero-shot	0,696	0,695
GPT-4o-mini few-shot	0,693	0,686
GPT-4o zero-shot (SC=3)	0,729	0,729
RoBERTa-large + Optuna	0,738	0,728

RoBERTa fine-tuned bije GPT-4o prcingiem 0\$ inferencji.
Bije **baseline z literatury** (RoBERTa $\sim 0,62$) o **+12 pkt.**

Wyniki – klasyfikacja 6-klasowa

Model	accuracy	macro-F1
GPT-4o-mini zero-shot	0,298	0,279
GPT-4o-mini few-shot	0,324	0,310
GPT-4o few-shot (K=1, SC=1)	0,344	0,356
RoBERTa-large + Optuna	0,357	0,359
RoBERTa-large + LIAR-PLUS	0,383	0,380
Wang 2017 (Hybrid CNN + meta)	0,274	–
<i>Performance ceiling lit.</i>	~0,32	–

Wyraźnie powyżej sufitu literatury (0,32) dzięki LIAR-PLUS.

Rozszerzona wersja LIAR (Alhindi 2018):

- Dodaje pole `justification` – uzasadnienie fact-checkera
- 99% próbek ma niepuste pole
- Median długości tekstu: 22 → 100 tokenów
- `Max_length` tokenizacji: 128 → 256

Efekt na 6kl:

- Accuracy: 0,357 → 0,383 (+2,6 pkt)
- Macro-F1: 0,359 → 0,380 (+2,1 pkt)
- ROC AUC: 0,77 – model dobrze rankuje, nawet jeśli granice klas są rozmyte

LLM prompting – GPT vs Qwen open-source

GPT (OpenAI API)

- gpt-4o-mini i gpt-4o
- **Structured Outputs:** JSON schema, enum etykiet → 0% unparsed
- **Few-shot kNN:** K=3 demo na klasę przez TF-IDF cosine
- **Self-consistency:** N=3 niezależne predykcje + voting większościowy
- Płatne (\$~2.50 per pełny test 6kl FS)

Qwen 2.5 3B (open-source)

- Lokalnie na T4 Kaggle (free)
- Zero-shot, anglojęzyczny prompt
- Deterministyczne dekodowanie (do_sample=False)
- Brak Structured Outputs (parser regex)
- Inferencja na 1267 próbkach ~5–10 min

Model	2kl acc	2kl F1	6kl acc	6kl F1
GPT-4o-mini ZS	0,696	0,695	0,298	0,279
GPT-4o ZS (SC=3)	0,729	0,729	—	—
GPT-4o 6kl FS	—	—	0,344	0,356
Qwen 2.5 3B ZS	0,564	0,559	0,196	0,154

Qwen 3B = *lower bound* dla LLM bez fine-tuningu.

Trudność wariantu 6-klasowego

Dlaczego 6kl jest dramatycznie trudniejsze:

- ❶ **Subiektywność** – granice `barely-/half-/mostly-true` nawet dla anotatorów PolitiFact są niejednoznaczne
- ❷ **Wymaga wiedzy o świecie** – RoBERTa pretrenowana na Wikipedia/książkach, nie aktualnych newsach politycznych
- ❸ **Niezbalansowane klasy** – `pants-fire` tylko 8%
- ❹ **Anotacyjny sufit** – ludzki ekspert też nie osiąga 100% zgodności

Eksperyment	Czas	Per próbka
GPT-4o-mini (API) – 1267 próbek		
2kl zero-shot	94 s	75 ms
2kl few-shot	163 s	130 ms
6kl zero-shot	714 s (~12 min)	560 ms
6kl few-shot	4001 s (~67 min)	3,2 s
GPT-4o (API, próba 2)		
2kl zero-shot SC=3	160 s	125 ms
6kl few-shot K=1 SC=1	2007 s (~33 min)	1,6 s
Qwen 2.5 3B (lokalnie, T4)		
2kl + 6kl zero-shot	~15 min	—
RoBERTa-large (A100, trening + ewaluacja)		
2kl trening 5 epok	~10 min	—
Optuna 2kl (20 triali)	~2 h	—
6kl_plus 7 epok	~25 min	—

- **Fine-tuning vs prompting:**
 - 2kl: RoBERTa-large $\geq$ GPT-4o (lokalnie, 0\$ inferencji)
 - 6kl: GPT-4o $\geq$ RoBERTa (wiedza o świecie)
 - RoBERTa-large + LIAR-PLUS – nasze najlepsze 6kl
- **Few-shot nie pomaga** w fact-checkingu (brak transferu wiedzy)
- **Structured Outputs** – musi być (z 11% unparsed do 0%)
- **Macro-F1, nie accuracy** – niezbalansowane klasy
- **Performance ceiling 6kl** ($\sim 0,32$) przekroczyliśmy dzięki LIAR-PLUS