

Wykrywanie fake news

Porównanie modeli językowych na zbiorze LIAR

Czerwiec 2026

Klasyfikacja prawdziwości wypowiedzi politycznych na **zbiorze LIAR**.

Dwa warianty zadania:

- **Binarna (2kl)**: fake / real
- **Sześcioklasowa (6kl)**: pants-fire, false, barely-true, half-true, mostly-true, true

Porównujemy trzy paradygmaty:

- 1 **Fine-tuning encodera** – RoBERTa-large
- 2 **Prompting LLM (płatny)** – GPT-4o-mini, GPT-4o
- 3 **Prompting LLM (open-source)** – Qwen 2.5 3B

- 12 791 krótkich wypowiedzi z PolitiFact (Wang 2017)
- Splits: train 10 240, val 1 284, test 1 267
- Każda wypowiedź ma: treść, mówcę, partię, historię prawdziwości
- Tematy: gospodarka, opieka zdrowotna, podatki, edukacja, wybory, imigracja

Trudność:

- Niezbalansowane klasy (najrzadsza pants-fire = 8%)
- Granice między klasami subiektywne – nawet fact-checkerzy się nie zgadzają
- Wymaga wiedzy o świecie, nie tylko analizy stylu

Systematyczny przegląd literatury (emergentmind.com) potwierdza:

- **6kl**: accuracy nie przekracza $\sim 0,32$
- **2kl**: $\sim 0,62$ (SVM/RoBERTa baseline)
- Modele drzewiaste: 99% train, ale 25% test = czysty overfit

Nawet Wang 2017 (oryginalny paper LIAR) osiągnął tylko **0,274 acc** dla 6kl.

Dlaczego roberta-large (355M parametrów):

- **160 GB** korpus pretreningu vs 16 GB BERT
- Dynamiczne maskowanie, brak NSP
- Encoder-only – produkuje wektor reprezentacji, idealne do klasyfikacji

Tekst wejściowy łączy wiele cech:

```
{speaker} ({party}, past lies: N, past truths: M): {statement}  
Subject: {subject} Context: {context}
```

Techniki podnoszące jakość

- **Wagi klas** (Cross-Entropy z $w_c = N/(C \cdot n_c)$)
- **Label smoothing** ($\varepsilon = 0,1$)
- **Optuna** – 20 trials, TPE sampler, MedianPruner
- **Early stopping** po val macro-F1
- **Mixed precision bfloat16** – $2\times$ szybciej na A100
- **Linear warmup + decay** schedulera lr
- **Structured Outputs** (GPT) – JSON schema, 0 unparsed
- **Self-consistency** (GPT) – $N=3$ niezależne predykcje + voting
- **Few-shot kNN retrieval** – TF-IDF cosine similarity

Selekcja po macro-F1, nie accuracy – niezbalansowane klasy.

Najlepsze hiperparametry (Optuna 2kl)

20 triali TPE + MedianPruner, ~2h na A100:

parametr	wartość
learning rate	$5,79 \cdot 10^{-6}$
weight decay	0,124
epochs	5
batch size	8
val macro-F1	0,7435

Wyniki – klasyfikacja binarna (2kl)

Model	accuracy	macro-F1
GPT-4o-mini zero-shot	0,696	0,695
GPT-4o-mini few-shot	0,693	0,686
GPT-4o zero-shot (SC=3)	0,729	0,729
RoBERTa-large + Optuna	0,738	0,728

RoBERTa fine-tuned bije GPT-4o prcingiem 0\$ inferencji.
Bije **baseline z literatury** (RoBERTa $\sim 0,62$) o **+12 pkt.**

Wyniki – klasyfikacja 6-klasowa

Model	accuracy	macro-F1
GPT-4o-mini zero-shot	0,298	0,279
GPT-4o-mini few-shot	0,324	0,310
GPT-4o few-shot (K=1, SC=1)	0,344	0,356
RoBERTa-large + Optuna	0,357	0,359
RoBERTa-large + LIAR-PLUS	0,383	0,380
Wang 2017 (Hybrid CNN + meta)	0,274	–
<i>Performance ceiling lit.</i>	~0,32	–

Wyraźnie powyżej sufitu literatury (0,32) dzięki LIAR-PLUS.

Rozszerzona wersja LIAR (Alhindi 2018):

- Dodaje pole `justification` – uzasadnienie fact-checkera
- 99% próbek ma niepuste pole
- Median długości tekstu: 22 → 100 tokenów
- `Max_length` tokenizacji: 128 → 256

Efekt na 6kl:

- Accuracy: 0,357 → 0,383 (+2,6 pkt)
- Macro-F1: 0,359 → 0,380 (+2,1 pkt)
- ROC AUC: 0,77 – model dobrze rankuje, nawet jeśli granice klas są rozmyte

Qwen 2.5 3B – baseline open-source

Inferencja na T4 (Kaggle), zero-shot, anglojęzyczny prompt:

Wariant	accuracy	macro-F1
Qwen 2.5 3B – 2kl ZS	0,564	0,559
Qwen 2.5 3B – 6kl ZS	0,196	0,154

Wnioski:

- 3B model bez fine-tuningu jest zdecydowanie słabszy od GPT-4o
- Dolne ograniczenie (*lower bound*) dla podejścia LLM-prompting open-source
- Pokazuje że **skala modelu i jakość pretreningu OpenAI mają znaczenie**

Trudność wariantu 6-klasowego

Dlaczego 6kl jest dramatycznie trudniejsze:

- ❶ **Subiektywność** – granice `barely-/half-/mostly-true` nawet dla anotatorów PolitiFact są niejednoznaczne
- ❷ **Wymaga wiedzy o świecie** – RoBERTa pretrenowana na Wikipedia/książkach, nie aktualnych newsach politycznych
- ❸ **Niezbalansowane klasy** – `pants-fire` tylko 8%
- ❹ **Anotacyjny sufit** – ludzki ekspert też nie osiąga 100% zgodności

- **Fine-tuning vs prompting:**
 - 2kl: RoBERTa-large $\geq$ GPT-4o (lokalnie, 0\$ inferencji)
 - 6kl: GPT-4o $\geq$ RoBERTa (wiedza o świecie)
 - RoBERTa-large + LIAR-PLUS – nasze najlepsze 6kl
- **Few-shot nie pomaga** w fact-checkingu (brak transferu wiedzy)
- **Structured Outputs** – musi być (z 11% unparsed do 0%)
- **Macro-F1, nie accuracy** – niezbalansowane klasy
- **Performance ceiling 6kl** ($\sim 0,32$) przekroczyliśmy dzięki LIAR-PLUS